

Leitfaden zur manuellen Datenbereinigung

Arbeitsanleitung für studentische Hilfskräfte für das Projekt “Building Embodied Publics” (Stand: 15.03.2026)

Inhaltsverzeichnis

Inhaltsverzeichnis	1
Kontakt	2
Ziel dieses Dokuments	3
Überblick über die Daten	3
Was enthält die Tabelle zur manuellen Datenbereinigung?	3
Wichtige Hinweise	3
1. Identifikatoren	4
2. Informationen zur Performance	4
3. Custom Felder für die manuelle Datenbereinigung	5
Grundprinzipien beim Arbeiten mit Daten	8
Änderungen müssen nachvollziehbar bleiben	8
Einheitlichkeit ist wichtiger als starke Differenzierung	8
Beispiel	8
Beispiel	8
Vorsicht bei automatischen Änderungen	8
Niemals ganze Spalten löschen	8
Lieber einmal zu oft und redundant speichern	9
Klare und nachvollziehbare Dateibenennungen	9
Format für Arbeitsdateien	9
Beispiel	9
Workflow zur Datenbereinigung	9
Öffnen der Tabelle	9
Erstellen von Spaltenübersichten: Facetten	11
Vorgehen	12
Bearbeiten der Daten	13
Änderungen rückgängig machen	14
Speichern und Ablage der Tabelle	15
FAQ, Beispiele und Randfälle	16
Randfall: Mögliche Fehlzuordnung der Location durch generische Description	16
Beispiel	16
Lösung	17
Gesamte Datenübersicht	18
1. Identifikatoren	18
2. Technische Informationen	Error! Bookmark not defined.
3. Plattformspezifische Informationen	20
4. Informationen zur Performance	21
5. Custom Felder für die manuelle Datenbereinigung	22

Kontakt

Bei Fragen oder Unklarheiten zu diesem Dokument, zur Datenbereinigung oder zum zugehörigen Forschungsprojekt stehe ich gerne zur Verfügung:

M.A. Cristian Ortega Singer (er/they)

Doktorand & Wissenschaftlicher Mitarbeiter

GRK 2806 „Literatur und Öffentlichkeit“

Friedrich-Alexander-Universität Erlangen-Nürnberg

Mail: cris.ortega@fau.de

<https://www.literaturundoeffentlichkeit.phil.fau.de/faudir/cristian-ortega-singer/>

Ziel dieses Dokuments

Dieser Leitfaden erklärt, wie die Daten in der Datei **manuelle-datenarbeit_descr-title.csv** manuell überprüft und bereinigt werden sollen.

Die Daten sind Teil des Promotionsprojekts „Building Embodied Publics: A Multimodal Corpus Study of Corporeality and Audience Engagement in Poetry Slam“ zur multimodalen Untersuchung von Körperlichkeit in Poetry Slam. Für das Projekt wurden 2349 Videos vom YouTube - Channel „Kampf der Künste TV“ mit zusätzlichen Informationen zu den Videos durch die Plattform heruntergeladen. Diese zusätzlichen Informationen zu den Videos nennt man Metadaten.

Deine Aufgabe ist es, diese Metadaten aufzubereiten, damit sie für spätere Analysen genutzt werden können. Dabei muss jede Zeile in der Tabelle **manuelle-datenarbeit_descr-title.csv** überprüft und nach festgelegten Regeln Spalten in der Tabelle befüllt werden.

Die Metadaten werden im Projekt nicht nur von Menschen gelesen, sondern auch von Programmen automatisiert eingelesen. Deshalb ist es besonders wichtig, dass die aufbereiteten Informationen einheitlich, vollständig und korrekt strukturiert vorliegen.

Dieses Dokument hilft dabei, diese hohe Qualität und Einheitlichkeit besser zu erreichen und Ungenauigkeiten, die durch die Bearbeitung durch mehrere Menschen entstehen, zu reduzieren.

Überblick über die Daten

Was enthält die Tabelle zur manuellen Datenbereinigung?

Die Tabelle besteht derzeit aus Metadaten zu 2349 individuellen Videos, die auf dem YouTube-Kanal *Kampf der Künste TV* hochgeladen wurden.

Wichtige Hinweise

- Eine Zeile = ein Datensatz zu einem Video
- Jede Spalte enthält nur eine Art Information
- Änderungen dürfen nur innerhalb der definierten Regeln und der **Custom Felder für manuelle Datenbereinigung** vorgenommen werden

Die Tabelle enthält Informationen, die von der Plattform YouTube zu jedem Video zur Verfügung gestellt werden. Die Tabelle **manuelle-datenarbeit_descr-title.csv** ist dabei ein Auszug, der spezifisch für die manuelle Datenbereinigung zur Verfügung gestellt wird. Sie beinhaltet für eine bessere Übersichtlichkeit nicht alle verfügbaren Informationen zu den Videos.

Die Tabellen werden nach erfolgreicher manueller Annotation wieder anhand von Identifikatoren zusammengeführt. Für eine vollständige Übersicht über alle verfügbaren Informationen ist eine Datenübersicht am Ende des Dokuments angehängt.

Die Informationen in der Tabelle **manuelle-datenarbeit_descr-title.csv** beinhalten Informationen aus folgenden Kategorien:

1. Identifikatoren
2. **Informationen zur Performance**
3. **Custom Felder für die manuelle Datenbereinigung**

Besonders relevant für die manuelle Datenbereinigung sind die Kategorien 2. Informationen zur Performance und 3. Custom Felder für die manuelle Datenbereinigung.

Wichtig! Der Identifikator **id** wird genutzt, um die Tabellen im Anschluss zusammenzuführen und darf nicht verändert werden.

1. Identifikatoren

Spalte	Bedeutung	Beispiel
id	Einzigartiger Identifikator des Videos, der von YouTube beim Upload auf die Plattform vergeben wird. Wird im Forschungsprojekt genutzt, um alle generierten Dateien zu einem Video miteinander zu verlinken.	gDEoAJeGbJ8
webpage_url	URL des spezifischen YouTube-Videos.	https://www.youtube.com/watch?v=gDEoAJeGbJ8

2. Informationen zur Performance

Spalte	Bedeutung	Beispiel
description	Veröffentlichte Beschreibung des Videos.	➡ Tickets für Best of Poetry Slam Day @ Elbphilharmonie: https://bit.ly/49nHND2 ----- ----- ➡ Artist: Hannah Habberger, https://www.instagram.com/hannahgabsleiderschon/ ➡ Stage: Deutsches Schauspielhaus, Hamburg ➡ Poetry Slam TV Website: http://www.poetryslamtv.de/ ➡ Exquisite Poetry Slam Liveshows: https://bit.ly/407yTpG ➡ Instagram: https://bit.ly/42tEYyh ➡ Tiktok: https://bit.ly/3yUqDx9 ➡ Facebook: https://bit.ly/3LGg9ZN ➡ Podcast: https://spoti.fi/3IE3HiF ➡ Poetry Slammer*innen buchen: https://bit.ly/3LFLUSM ➡ Abonnieren & Glocke aktivieren: https://www.youtube.com/c/PoetrySlamTV

		Bei Fragen zur Lizenzierung des Videomaterials wendet euch bitte an die im Kanal hinterlegte geschäftliche Email-Adresse. Poetry Slam TV by Kampf der Künste Poetry Slam TV - das ist euer Zugang zu allem, was mit Slam Kultur zu tun hat. Clips, Podcasts, Specials, Audio, Video, Bild & Ton! Wir bündeln das alles, zünden ein Feuerwerk an Spoken Word, Stories, Lyrik, Satire und Comedy und knallen die Rakete aus unserer Homepage in Hamburg in die weiten Himmel des Internets. Ob Live-Mitschnitte oder Behind the Scenes-Material – wir sind immer dort vor Ort, wo es hoch hergeht und halten drauf! Ganze Slam-Videos stehen gleichberechtigt neben Reels und Snippets, hier findet ihr genauso Auftritte von alten Legenden wie von den neuen und aufstrebenden Stars von morgen. Denn Slam ist überall, ihr müsst nur hingucken! Und das geht nun mal am besten auf Poetry Slam TV. Eine Symbiose aus all dem, was ihr liebt und dazu noch mehr. Poetry Slam TV by Kampf der Künste – euer Eintritt ins Slam-Paradies!
title	Veröffentlichter Titel des Videos.	Conni sch****t auf alles Hannah Haberberger Poetry Slam TV
tags	Bei der Veröffentlichung vergebene Tags zum Video getrennt durch " ".	poetryslam poetryslam deutsch poetry slam poetry slam deutsch deutsch poetryslam deutsch poetry slam poetryslam gewinner poetry slam gewinner poetryslam auftritt poetry slam auftritt poetry slam tv kampf der künste best of poetry slam hannah haberberger adoption kinderbuch conni pixi buch conni scheißt auf alles comedy satire

3. Custom Felder für die manuelle Datenbereinigung

Spalte	Bedeutung	Beispiel
AUTHOR	Name der auftretenden Person Regeln: - In GROSSBUCHSTABEN - Format: VORNAME NACHNAME	JANN WATTJES

	- Keine Zusätze wie Slam Poet oder Moderator	
AUTHOR_2	Name der zweiten auftretenden Person, falls vorhanden Regeln: - Siehe Feld AUTHOR	AUGUST KLAR
TEAM_NAME	Name des Teams, falls die Performance als Team stattfindet und der Teamname angegeben wurde Regeln: - IN GROSSBUCHSTABEN - Ohne den vorangestellten Zusatz "Team" - Ausnahme: TEAM POETRY SLAM TEAM (der Zusatz gehört hier zum Namen)	RABATT AUF ALIENZUBEHÖR
LOCATION	Name des Veranstaltungsortes, an dem die Performance stattfindet Regeln: - IN GROSSBUCHSTABEN - Nur der Name der Location - Keine Ortsnamen - Keine Veranstaltungsnamen Wichtig! Überprüfe, ob die angegebene Location nicht nur ein Veranstaltungshinweis aus der Beschreibung ist.	ERNST DEUTSCH THEATER
CITY	Name der Stadt des Veranstaltungsortes Regeln: - IN GROSSBUCHSTABEN - Name der ganzen Stadt - Keine Orts- und Stadtteile	HAMBURG
TITLE	Titel des performten Textes. Dieser muss oft aus dem Videotitel extrahiert werden. Regeln: - Unveränderte Schreibweise - Keine Angaben zum Format (z.B. Best Of, Dreikampf) - Mehrere Texttitel werden mit " " getrennt	Der Techniker Slampoese auf Papier! In drei Akten!
EVENT_TYPE	Angaben zum Typ der Veranstaltung, falls konkret angegeben. Eine Textfacette lohnt sich für eine Übersicht über Veranstaltungstypen. Neue Typen können nach eigenem Ermessen hinzugefügt werden. Regeln: - IN GROSSBUCHSTABEN - So spezifisch wie nötig, so generell wie möglich Wichtig! Überprüfe, ob der angegebene Typ nicht nur ein Veranstaltungshinweis aus der Beschreibung ist.	BEST OF POETRY SLAM

DATE	Datumsangaben aus title und description, falls konkret angegeben. Regeln: - Format: YYYY-MM-DD - Falls der Tag nicht bekannt ist: YYYY-MM-00 - Falls das Jahr nicht bekannt ist: 0000-MM-DD - Falls nur das Jahr bekannt ist: YYYY-00-00	2013-04-00
EDITED	Markiert, ob eine Zeile bereits überprüft wurde. Regeln: - Möglicher Wert: Y - Erst markieren, wenn alle Custom Felder überprüft wurden	Y
COMMENT	Hier können Unsicherheiten und Anmerkungen dokumentiert werden. Regeln: - Format: [KÜRZEL DD-MM-YYYY] Kommentar - Das individuelle Kürzel ist frei wählbar (z.B. erster Buchstabe Vorname + erster Buchstabe Nachname) - Einmal gewählt, sollte immer das gleiche Kürzel verwendet werden.	[CO 13.03.2026] Unsicher ob das wirklich der Teamname ist.

Grundprinzipien beim Arbeiten mit Daten

Änderungen müssen nachvollziehbar bleiben

- Keine Informationen löschen ohne Grund
- Wenn etwas unklar ist → Kommentar in der Spalte **COMMENT** notieren oder direkt nachfragen
- Zweifelhafte Fälle markieren statt raten

Einheitlichkeit ist wichtiger als starke Differenzierung

Alle Einträge müssen gleich geschrieben sein, sonst funktionieren spätere Analysen nicht.

Beispiel

Falsch:

Hannah Haberberger
Hannah Haberberger
Hannah H.
HANNAH HABERBERGER

Richtig:

HANNAH HABERBERGER

Falls es unklar ist, ob wirklich die gleiche Person oder der gleiche Ort gemeint ist, wird trotzdem lieber das Detail behalten und ein Kommentar im Feld **COMMENT** hinterlassen.

Beispiel

AUTHOR:

ABDUL CHAHIN
ABDUL KADER CHAHIN

COMMENT:

[CO 14.03.2026] Unsicher ob, das die gleiche Person ist.

Vorsicht bei automatischen Änderungen

Sei vorsichtig beim automatischen Ersetzen oder Sortieren, wenn du nicht sicher bist. Sei dir sicher, dass wirklich nur das geändert wird, was du ändern willst. Speichere vorher deine Arbeit ab.

Niemals ganze Spalten löschen

Auch Spalten, die nicht für die aktuelle Bereinigung relevant sind, müssen unverändert erhalten bleiben. Die anschließende Zusammenführung von Informationen kann sonst beeinträchtigt werden. Das Hinzufügen von weiteren Spalten für den Arbeitsprozess ist erlaubt.

Lieber einmal zu oft und redundant speichern

Regelmäßiges Speichern von Arbeitsfortschritt ist essenziell. Hier gilt das Prinzip lieber einmal zu oft, als den Verlust von mehreren Stunden Arbeit riskieren.

Es empfiehlt sich dabei nicht nur eine Datei immer wieder zu überschreiben, sondern drei Versionen mit den letzten drei Änderungsständen zu behalten. Das ermöglicht die Wiederherstellung der Daten, falls ein Fehler bei der Bearbeitung passiert. Klare Dateibenennungen und Ablagen helfen bei der Übersichtlichkeit.

Klare und nachvollziehbare Dateibenennungen

Damit Arbeitsstände später nachvollzogen und wiedergefunden werden können, müssen Dateien eindeutig und konsistent benannt werden.

Format für Arbeitsdateien

YYYY-MM-DD-v[NR]_manuelle-datenarbeit_descr-title.csv

Zuerst Jahresangabe, dann Monat, dann Jahr, optional Versionsnummer bei mehreren Speicherständen an einem Tag; jeweils mit “-” getrennt.

Danach der unveränderte Filename: “_manuelle-datenarbeit_descr-title.csv”

Beispiel

2026-03-13-v2_manuelle-datenarbeit_descr-title.csv

2026-03-15_manuelle-datenarbeit_descr-title.csv

Workflow zur Datenbereinigung

Öffnen der Tabelle

Wir arbeiten mit dem Tool OpenRefine: <https://openrefine.org/>


Wichtig! Nicht Excel nutzen!

→ Macht Schwierigkeiten mit Encoding und Dateiformaten! Verändert automatisch Informationen!

1. Herunterladen der OpenRefine Executable unter <https://openrefine.org/download>
 2. Zip-Ordner entpacken
 3. OpenRefine.exe auswählen und Doppelklicken
- ➔ Ein Konsolenfenster öffnet sich und startet OpenRefine im Browser

Sollte sich OpenRefine nicht automatisch in einem Browserfenster öffnen oder wenn OpenRefine in einem anderen Browser geöffnet werden soll, kann die Anwendung auch über <http://127.0.0.1:3333/> erreicht werden. Um OpenRefine zu beenden, schließe das Konsolenfenster.


Startansicht im Browser



4. Wähle **Datei Auswählen** und suche nach der gewünschten Datei im Explorer

5. Wähle anschließend **Nächste**

➔ Datenvorschau mit Importoptionen wird angezeigt



5. Überprüfe die Importoptionen anhand der folgenden Tabelle oder dem Screenshot. Die Werte sollten automatisch vorgewählt sein. Wähle anschließend **Projekt erstellen**.

Option	Wert
Zeichen kodierung	UTF-8
Spalten werden getrennt durch	Kommas (CSV)
Zeichen verwenden ____ zum Einschließen von Zellen mit Spaltentrennern	Ausgewählt: “

Nächste ____ Zeile(n) als Spaltenüberschriften analysieren	Ausgewählt: 1
Leere Zeilen speichern	Ausgewählt
Speichern von leeren Zellen als null-Werte	Ausgewählt
Führende & nachgestellte Leerzeichen aus Zeichenfolgen entfernen	Nicht Ausgewählt
Erste ignorieren ____ Zeile(n) am Dateianfang	Nicht Ausgewählt
Spaltennamen (durch Kommata getrennt)	Nicht Ausgewählt
Anfängliche ____ Datenzeile(n) verwerfen	Nicht Ausgewählt
Maximale Lasten ____ Datenzeile(n)	Nicht Ausgewählt
Analysiere Zelltext in Zahlen, Datumsangaben, ...	Nicht Ausgewählt
Dateiquelle speichern	Nicht Ausgewählt
Archivdatei speichern	Nicht Ausgewählt

➔ Datenset ist geladen

OpenRefine 2026 03 13 manuelle datenarbeit descr title csv [Permalink](#) [Öffnen...](#) [Export](#) [Hilfe](#)

Facette / Filter [Erweiterungen](#) [Wikibase](#)

Rückgängig / Wiederholen 0/0

Anzeigen als: **Zeilen** Datensätze Anzeigen: 5 10 25 50 100 500 1000 Zeilen [« erste](#) [« vorherige](#) 1 [nächste](#) [» letzte](#) [»](#)

	Alle	id	description	title	SPLIT_TITLE 1 1	SPLIT_TITLE 1 2	SPLIT_TITLE 2	AUTHOR	AUTHOR_2	TEAM_NAME	LOCATION	CITY	TITLE	EVENT TYPE	DATE
1.	wtSefrOBZG	Idee - PUNKTE-STREIFEN Drehbuch - Elisa Unger und Christoph Drösig	Kampf der Künste - Kino-Trailer 2012	Kampf der Künste - Kino-Trailer 2012				SNONES	SNONES	SNONES	SNONES	SNONES	Kampf der Künste - Kino-Trailer 2012	OTHER	2012-00-00
		Carl Moderator - Michel Abdolahi Bülow - Christoph Drösig Anja - Jenny Bins Fried - Stephan Orkowski Chesin - Jasmin Maeder Kai - Katharina Stüber Illa - Evelyn Gundacker Olli - Gianni Sebastina Ermanno Sculfort Hagen - Ulrich Meinke													
		Team Produktion - Moritz Preiller Regie - Elisa Unger Kamera - Patrick Popow Kameraassistent - Paul Störing Ton - Philipp Dietrich Licht - Steffen Zeugner Lichtassistent - Ferry Seidel Selbstaufnahmeleitung - Kordula Hildebrand Selbstaufnahmeleitungsassistent - Franca Engel													
2.	BH8Jta7h0y4	April 2012 in Hamburg im Uebel & Gefährlich	Renato Kaiser beim Bunker Slam - "Meine Generation"					RENATO KAISER	SNONES	SNONES	UEBEL & GEFAEHRlich	HAMBURG	Meine Generation	BUNKER SLAM	2013-04-00
3.	bckLFLpWEg	Oktober 2012 in Hamburg	Renato Kaiser beim Best Of Poetry Slam - "Nicht"					RENATO KAISER	SNONES	SNONES	SNONES	HAMBURG	Nicht	BEST OF POETRY SLAM DAY	2012-10-00
4.	eDrDaiRwUj0	Oktober 2012 in Hamburg im Ernst Deutsch Theater	Renato Kaiser beim Best Of Poetry Slam - "15 Minuten Einsicht"					RENATO KAISER	SNONES	SNONES	ERNST DEUTSCH THEATER	HAMBURG	15 Minuten Einsicht	BEST OF POETRY SLAM DAY	2012-10-00

Erstellen von Spaltenübersichten: Facetten


OpenRefine bietet eine Funktion namens **Facetten**, mit der schnell ein Überblick über alle Werte in einer Spalte erstellt werden kann.

Diese Funktion ist besonders hilfreich, um:

- unterschiedliche Schreibweisen zu erkennen
- Tippfehler zu finden
- häufige Werte zu identifizieren und sich an ihnen zu orientieren
- die Daten zu filtern

Vorgehen

1. In der gewünschten Spalte den kleinen Pfeil neben dem Spaltennamen auswählen
→ Im Menü **Facette** → **Textfacette** auswählen



- OpenRefine erstellt eine Liste aller in der Spalte vorkommenden Werte

Einzelne Werte können in der Facettenübersicht ausgewählt werden.

Facette / Filter

2128 matching Zeilen (2349 total)

Rückgängig / Wiederholen 0 / 0

Aktualisieren zurücksetzen Alles entfernen

1 Auswahl Sortieren nach: Name Anzahl Cluster

Y 221

(blank) 2128 exclude

Anzahl Facetten per Auswahl

description	title	SPLIT_TITLE
Oktober 2012 in Hamburg im Ernst Deutsch Theater	Renato Kaiser beim Best Of Poetry Slam - "Pygmalion Reloaded / Mimose / Mauerblümchen"	Renato Kaiser beim Best Of Poetry Slam
April 2013 in Hamburg im Übel & Gefährlich	Renato Kaiser beim Bunker Slam - "Es gibt doch diese Momente"	Renato Kaiser beim Bunker Slam
Mona Harry beim Bunker	Mona Harry beim Bunker	Mona Harry beim Bunker Slam im

→ Es werden nur Zeilen mit dem ausgewählten Wert angezeigt

Wichtig! Vor dem Export müssen alle Facetten wieder entfernt werden! Es werden sonst nicht alle Daten exportiert!

Bearbeiten der Daten

Die manuelle Datenbereinigung erfolgt Zeile für Zeile.

Für jede Zeile werden folgende Schritte durchgeführt:

1. Titel des Videos prüfen
2. Beschreibung (**description**) lesen
3. Custom Felder ausfüllen
4. Feld **EDITED** mit **Y** markieren

Es werden insbesondere folgende Informationen gesucht:

- Name der auftretenden Person
- Name der zweiten auftretenden Person (falls vorhanden)
- Teamname (falls vorhanden)
- Titel des Textes
- Veranstaltungsformat
- Location
- Stadt
- Datum
- Event Type

Wichtig! Lies die Beschreibungen zu jeder der Custom Felder ausführlich durch, bevor du mit der Bearbeitung beginnst.

Diese Informationen befinden sich häufig

- im Videotitel
- in der Beschreibung
- selten auch in Tags

Um ein Feld in OpenRefine zu bearbeiten, fahre über die zu bearbeitende Zelle und wähle **bearbeiten**.

IT_TITLE 2	AUTHOR	AUT
	\$ bearbeiten	\$NONE\$
	\$NONE\$	\$NONE\$

→ Ein Textfeld öffnet sich. Der Wert der ausgewählten Zelle kann bearbeitet werden.
Wähle **Anwenden** oder drücke **Enter**, um die Änderungen auf die Zelle anzuwenden.

title	SPLIT_TITLE 1 1	SPLIT_TITLE 1 2	SPLIT_TITLE 2	AUTHOR	AUTHOR_2	TEAM_NAME	LOCATION	CITY	TITLE
Slam im April 2013 Teil 1/3	Teil 1/3								
Fabian Navarro beim Bunker Slam - November 2012 Teil 1/2	Fabian Navarro beim Bunker Slam	November 2012 Teil 1/2		\$NONE\$					\$N
Mischa Sarim Verollet beim Best Of Poetry Slam im April 2013 Teil 2/3	Mischa Sarim Verollet beim Best Of Poetry Slam im April 2013 Teil 2/3			\$NONE\$					\$N

Datentyp: Text
 \$NONE\$
 Anwenden Auf alle identischen Zellen anwenden Abbrechen
 Eingabe Strg+Eingabe Esc

Trage nach vollständiger Bearbeitung der Zeile **Y** in das Feld **EDITED** ein.

2013 Teil 1/3	Fabian Navarro beim Bunker Slam - November 2012 Teil 1/2	Fabian Navarro beim Bunker Slam	November 2012 Teil 1/2	FABIAN NAVARRO	\$NONE\$	\$NONE\$	ÜBEL & GEFÄHRlich	HAMBURG	Teil 1/2	BUNKER SLAM	2012-11-00	Y	[CO 15.03.2026] Titel nicht vollständig
Mischa Sarim	Mischa Sarim Verollet			\$NONE\$	\$NONE\$	\$NONE\$	\$NONE\$	\$NONE\$	\$NONE\$	\$NONE\$	\$NONE\$		


Änderungen Rückgängig machen

Falls ein Fehler bei der Datenbearbeitung passiert, oder aus anderen Gründen Änderungen rückgängig gemacht werden sollen, ermöglicht OpenRefine eine Rückverfolgung der Schritte während deiner Session.

Wichtig! Die Rückverfolgung der Schritte ist nur innerhalb der laufenden Session möglich!

Wird OpenRefine geschlossen oder eine Datei neu importiert, können vorherige Änderungen nicht mehr rückgängig gemacht werden!

Wähle in OpenRefine in der linken Ansicht den Reiter **Rückgängig/Wiederholen**. Wähle einen vorherigen Schritt in der Datenverarbeitung.



→ Der Stand der Daten zu diesem Schritt wird geladen


Wichtig! Werden Änderungen an dem zurückgesetzten Stand vorgenommen, werden die rückgängig gemachten Schritte überschrieben.

Speichern und Ablage der Tabelle

Wichtig! Alle Facetten vor dem Export entfernen! Sonst sind die Daten nicht vollständig!

Um den Arbeitsstand zu speichern:

1. Wähle in der oberen rechten Ecke
Export → Kommagetrennter Wert



2. Vergib einen Dateinamen nach dem festgelegten Format für Arbeitsdateien:

YYYY-MM-DD-v[NR]_manuelle-datenarbeit_descr-title.csv

➔ Der aktuelle Arbeitsstand ist nun abgespeichert.

FAQ, Beispiele und Randfälle

Randfall: Mögliche Fehlzuordnung der Location durch generische Description

Beispiel

id	description	title
c84Ao tTtr8M	➔Artist: Anna Hader ➔Exquisite Poetry Slam Liveshows: https://bit.ly/407yTpG ➔Best of Poetry Slam Day @ Elbphilharmonie: https://bit.ly/3yVSj4N ➔Instagram: https://bit.ly/42tEYyh ➔Tiktok: https://bit.ly/3yUqDx9 ➔Facebook: https://bit.ly/3LGg9ZN ➔Podcast: https://spoti.fi/3lE3HiF ➔Poetry Slammer*innen buchen: https://bit.ly/3LFLUSM ➔Abonnieren & Glocke aktivieren: https://www.youtube.com/c/PoetrySlamTV Bei Fragen zur Lizenzierung des Videomaterials wendet euch bitte an die im Kanal hinterlegte geschäftliche Email-Adresse. Poetry Slam TV by Kampf der Künste Poetry Slam TV - das ist euer Zugang zu allem, was mit Slam Kultur zu tun hat. Clips, Podcasts, Specials, Audio, Video, Bild & Ton!	Anna Hader - Rap und die Liebe

	Wir bündeln das alles, zünden ein Feuerwerk an Spoken Word, Stories, Lyrik, Satire und Comedy und knallen die Rakete aus unserer Homepage in Hamburg in die weiten Himmel des Internets. Ob Live-Mitschnitte oder Behind the Scenes-Material – wir sind immer dort vor Ort, wo es hoch hergeht und halten drauf! Ganze Slam-Videos stehen gleichberechtigt neben Reels und Snippets, hier findet ihr genauso Auftritte von alten Legenden wie von den neuen und aufstrebenden Stars von morgen. Denn Slam ist überall, ihr müsst nur hingucken! Und das geht nun mal am besten auf Poetry Slam TV. Eine Symbiose aus all dem, was ihr liebt und dazu noch mehr. Poetry Slam TV by Kampf der Künste – euer Eintritt ins Slam-Paradies! https://kampf-der-kuenste.de/linkliste/	
--	---	--

Aus der Beschreibung geht nicht hervor, in welcher Location das konkrete Video gedreht wurde. Durch die generische Linkliste in der Beschreibung mit Hinweis auf den Best of Poetry Slam Day in der Elbphilharmonie könnte es zu einer Fehlzurordnung kommen.

Lösung

Immer überprüfen, ob hier nur auf eine Location hingewiesen wird, oder die Performance wirklich in dieser stattgefunden hat!

Wenn unsicher, Kommentar hinterlassen unter **COMMENT**.

Gesamte Datenübersicht

Die Informationen in **master.csv**, aus der der zur Verfügung gestellte Auszug **manuelle-datenarbeit_descr-title.csv** erstellt wurde, lassen sich in fünf Kategorien aufteilen:

- 1. Identifikatoren
- 2. Technische Informationen
- 3. Plattformspezifische Informationen
- 4. Informationen zur Performance
- 5. Custom Felder für die manuelle Datenbereinigung

1. Identifikatoren

Spalte	Bedeutung	Beispiel
id	Einzigtiger Identifikator des Videos, der von YouTube beim Upload auf die Plattform vergeben wird. Wird im Forschungsprojekt genutzt, um alle generierten Dateien zu einem Video miteinander zu verlinken.	gDEoAJeGbJ8
channel_id	Einzigtige ID für einen YouTube-Channel, der von YouTube bei der Erstellung eines Channels vergeben wird. Aktuell im Forschungsprojekt für alle Videos gleich, da nur Videos von einem Channel verwendet werden.	UCVIhh1u3j4hoJf33xY9JOZg
channel_url	URL des YouTube-Channels, von dem das Video veröffentlicht wurde. Aktuell im Forschungsprojekt für alle Videos gleich, da nur Videos von einem Channel verwendet werden.	https://www.youtube.com/channel/UCVIhh1u3j4hoJf33xY9JOZg
webpage_url	URL des spezifischen YouTube-Videos	https://www.youtube.com/watch?v=gDEoAJeGbJ8
channel	Öffentlicher Anzeigename des YouTube-Channels zum Zeitpunkt der Datenerhebung. Aktuell im Forschungsprojekt für alle Videos gleich, da nur Videos von einem Channel verwendet werden.	Kampf der Künste TV
info_json_file	Dateiname für die zum Video zugehörige info.json, aus der die Metadaten für "master.csv" ursprünglich entnommen wurden.	2024-10-09_gDEoAJeGbJ8.info.json
description_file	Dateiname für die zum Video zugehörige description. Diese beinhaltet die Videobeschreibung noch einmal gesondert, um gegen mögliche Encodingfehler durch	2024-10-09_gDEoAJeGbJ8.description

	Sonderzeichen abgesichert zu sein.	
json3_file	Dateiname für die zum Video zugehörige json3 mit der automatischen Transkription durch YouTube.	2024-10-09_gDEoAJeGbJ8.de.json3
thumbnail_file	Dateiname für das zum Video zugehörige Thumbnail.	2024-10-09_gDEoAJeGbJ8.webp
video_file	Dateiname für das beschriebene Video.	2024-10-09_gDEoAJeGbJ8.mkv
AUTHOR_ID	Einzigartiger Identifikator der*s Autor*in, der im Abgleich mit einem gesonderten Autor*innen-Register des Projekts generiert und referenziert wird	Aeb378b5640ff
AUTHOR_2_ID	Einzigartiger Identifikator der*s Autor*in, der im Abgleich mit einem gesonderten Autor*innen-Register des Projekts generiert und referenziert wird	A4d4ee1a962df

2. Technische Informationen

Spalte	Bedeutung	Beispiel
duration	Länge des Videos in Sekunden als numerischer Wert.	409
timestamp	Unix-Zeitstempel des Veröffentlichungszeitpunkts des Videos. Gibt Datum und Uhrzeit als Anzahl der Sekunden seit dem 1. Januar 1970 an.	1728493238
duration_string	Länge des Videos in dem von YouTube angezeigten Zeitformat.	6:49
epoch	Unix-Zeitstempel des Moments, in dem die Metadaten erhoben bzw. die info.json erstellt wurde.	1770977628
format	Vollständige technische Beschreibung des heruntergeladenen Videoformats, wie sie in der info.json hinterlegt ist. Kann Container, Auflösung, Bildrate und Audio-/Videocodecs enthalten.	299 - 1920x1080 (1080p50)+251 - audio only (medium)
format_id	Interne Kennung des von YouTube bzw. yt-dlp ausgewählten Downloadformats.	299+251
width	Breite des heruntergeladenen Videos in Pixeln.	1920
height	Höhe des heruntergeladenen Videos in Pixeln.	1080

resolution	Zusammenfassende Angabe der Bildauflösung als Text.	1920x1080
fps	Bildrate des Videos in Bildern pro Sekunde.	50
aspect_ratio	Seitenverhältnis des Videos, berechnet aus Breite und Höhe.	1.78

3. Plattformspezifische Informationen

Spalte	Bedeutung	Beispiel
view_count	Anzahl der Videoaufrufe zum Zeitpunkt der Datenerhebung	7643
age_limit	Altersfreigabe bzw. Altersbeschränkung des Videos laut Plattform. Bei regulären öffentlich zugänglichen Videos meist 0.	0
categories	Von YouTube vergebene inhaltliche Kategorie oder Kategorien des Videos getrennt durch " ", falls mehrere vorhanden sind.	Entertainment
live_status	Status des Videos im Hinblick auf Live-Streaming. Zeigt an, ob ein Video regulär veröffentlicht, live, künftig live oder ein ehemaliger Livestream ist.	not_live
media_type	Typ des Mediums. Im Forschungsprojekt "video", "livestream" oder "short"	video
comment_count	Anzahl der Kommentare unter dem Video zum Zeitpunkt der Datenerhebung.	7
like_count	Anzahl der Likes des Videos zum Zeitpunkt der Datenerhebung.	498
channel_follower_count	Anzahl der Abonnent*innen des Channels zum Zeitpunkt der Datenerhebung, soweit von YouTube in den Metadaten bereitgestellt.	206000
upload_date	Veröffentlichungsdatum des Videos auf YouTube im Format YYYYMMDD	20241009
was_live	Gibt an, ob das Video ursprünglich als Livestream übertragen wurde.	False
language	Von YouTube oder yt-dlp erkannte Hauptsprache des Videos bzw. der Metadaten.	de

4. Informationen zur Performance

Spalte	Bedeutung	Beispiel
description	Veröffentlichte Beschreibung des Videos.	➡ Tickets für Best of Poetry Slam Day @ Elbphilharmonie: https://bit.ly/49nHND2 ----- ----- ➡ Artist: Hannah Habegger, https://www.instagram.com/hannahgabsleiderschon/ ➡ Stage: Deutsches Schauspielhaus, Hamburg ➡ Poetry Slam TV Website: http://www.poetryslamtv.de/ ➡ Exquisite Poetry Slam Liveshows: https://bit.ly/407yTpG ➡ Instagram: https://bit.ly/42tEYyh ➡ Tiktok: https://bit.ly/3yUqDx9 ➡ Facebook: https://bit.ly/3LGg9ZN ➡ Podcast: https://spoti.fi/3lE3HiF ➡ Poetry Slammer*innen buchen: https://bit.ly/3LFLUSM ➡ Abonnieren & Glocke aktivieren: https://www.youtube.com/c/PoetrySlamTV Bei Fragen zur Lizenzierung des Videomaterials wendet euch bitte an die im Kanal hinterlegte geschäftliche Email-Adresse. Poetry Slam TV by Kampf der Künste Poetry Slam TV - das ist euer Zugang zu allem, was mit Slam Kultur zu tun hat. Clips, Podcasts, Specials, Audio, Video, Bild & Ton! Wir bündeln das alles, zünden ein Feuerwerk an Spoken Word, Stories, Lyrik, Satire und Comedy und knallen die Rakete aus unserer Homepage in Hamburg in die weiten Himmel des Internets. Ob Live-Mitschnitte oder Behind the Scenes-Material – wir sind immer dort vor Ort, wo es hoch hergeht und halten drauf! Ganze Slam-Videos stehen gleichberechtigt neben Reels und Snippets, hier findet ihr genauso Auftritte von alten Legenden wie von den neuen und aufstrebenden Stars von morgen. Denn Slam ist überall, ihr müsst nur hingucken! Und das geht nun mal am besten auf Poetry Slam TV.

		Eine Symbiose aus all dem, was ihr liebt und dazu noch mehr. Poetry Slam TV by Kampf der Künste – euer Eintritt ins Slam-Paradies!
title	Veröffentlichter Titel des Videos.	Conni sch***t auf alles Hannah Haberberger Poetry Slam TV
tags	Bei der Veröffentlichung vergebene Tags zum Video getrennt durch " ".	poetryslam poetryslam deutsch poetry slam poetry slam deutsch deutsch poetryslam deutsch poetry slam poetryslam gewinner poetry slam gewinner poetryslam auftritt poetry slam auftritt poetry slam tv kampf der künste best of poetry slam hannah haberberger adoption kinderbuch conni pixi buch conni schießt auf alles comedy satire

5. Custom Felder für die manuelle Datenbereinigung

Spalte	Bedeutung	Beispiel
AUTHOR	Name der auftretenden Person Regeln: - In GROSSBUCHSTABEN - Format: VORNAME NACHNAME - Keine Zusätze wie Slam Poet oder Moderator	JANN WATTJES
AUTHOR_2	Name der zweiten auftretenden Person, falls vorhanden Regeln: - Siehe Feld AUTHOR	AUGUST KLAR
TEAM_NAME	Name des Teams, falls die Performance als Team stattfindet und der Teamname angegeben wurde Regeln: - IN GROSSBUCHSTABEN - Ohne den vorangestellten Zusatz "Team" - Ausnahme: TEAM POETRY SLAM TEAM (der Zusatz gehört hier zum Namen)	RABATT AUF ALIENZUBEHÖR
LOCATION	Name des Veranstaltungsortes, an dem die Performance stattfindet Regeln: - IN GROSSBUCHSTABEN - Nur der Name der Location - Keine Ortsnamen - Keine Veranstaltungsnamen Wichtig! Überprüfe, ob die angegebene Location nicht nur ein Veranstaltungshinweis aus der Beschreibung ist.	ERNST DEUTSCH THEATER

CITY	Name der Stadt des Veranstaltungsortes Regeln: - IN GROSSBUCHSTABEN - Name der ganzen Stadt - Keine Orts- und Stadtteile	HAMBURG
TITLE	Titel des performten Textes. Dieser muss oft aus dem Videotitel extrahiert werden. Regeln: - Unveränderte Schreibweise - Keine Angaben zum Format (z.B. Best Of, Dreikampf) - Mehrere Texttitel werden mit “ “ getrennt	Der Techniker Slampoesie auf Papier! In drei Akten!
EVENT_TYPE	Angaben zum Typ der Veranstaltung, falls konkret angegeben. Eine Textfacette lohnt sich für eine Übersicht über Veranstaltungstypen. Neue Typen können nach eigenem Ermessen hinzugefügt werden. Regeln: - IN GROSSBUCHSTABEN - So spezifisch wie nötig, so generell wie möglich Wichtig! Überprüfe, ob der angegebene Typ nicht nur ein Veranstaltungshinweis aus der Beschreibung ist.	BEST OF POETRY SLAM
DATE	Datumsangaben aus title und description, falls konkret angegeben. Regeln: - Format: YYYY-MM-DD - Falls der Tag nicht bekannt ist: YYYY-MM-00 - Falls das Jahr nicht bekannt ist: 0000-MM-DD - Falls nur das Jahr bekannt ist: YYYY-00-00	2013-04-00
EDITED	Markiert, ob eine Zeile bereits überprüft wurde. Regeln: - Möglicher Wert: Y - Erst markieren, wenn alle Custom Felder überprüft wurden	Y
COMMENT	Hier können Unsicherheiten und Anmerkungen dokumentiert werden. Regeln: - Format: [KÜRZEL DD-MM-YYYY] Kommentar - Das individuelle Kürzel ist frei wählbar (z.B. erster Buchstabe Vorname + erster Buchstabe Nachname) - Einmal gewählt, sollte immer das gleiche Kürzel verwendet werden.	[CO 13.03.2026] Unsicher ob das wirklich der Teamname ist.